



DESARROLLO BIG DATA CON PYTHON

TEMA 2. Paradigma Big Data: de
Hadoop a Spark



Contenidos Tema 2

- / 1. Concepto de Big Data
- / 2. Hadoop y su Ecosistema (HDFS, MapReduce): base histórica
- / 3. Limitaciones del Ecosistema Hadoop Tradicional
- / 4. Motivación para Spark
- / 5. Apache Spark vs Hadoop

El **análisis de datos** es una **destreza crítica** en un mundo como el actual: un **mundo rodeado y guiado por datos**. Ejemplos:

1. Analista de negocio que intenta obtener información útil y con sentido de datos de ventas.
2. Científico/a responsable de analizar resultados de reiterados experimentos.

Es esencial entender los fundamentos del proceso de análisis de datos, pero ...

¿Qué es el Análisis de Datos?

El análisis de datos es el proceso de **recolectar, inspeccionar, limpiar, transformar, e interpretar datos** para **descubrir información útil, obtener conclusiones**, y brindar apoyo a la **toma de decisiones**.


El análisis de datos es el proceso de **recolectar inspeccionar, limpiar, transformar, e interpretar datos** para **descubrir información útil, obtener conclusiones**, y brindar apoyo a la **toma de decisiones**.

- Análisis de Datos = Enfoque sistemático para **entender patrones, tendencias, y relaciones** en un conjunto de datos (*dataset*)



Datos vs. Información vs. Conocimiento

DATOS	Hechos (valores) en crudo, sin contexto ni interpretación	36°C (Tokio, 36°C, 30-07-2025)
INFORMACIÓN	Datos organizados y con contexto	“Hoy la temperatura en Tokio es de 36°C”
CONOCIMIENTO	Comprensión de la información para la toma de decisiones	“Debo beber mucho líquido y quedarme a la sombra si estoy en Tokio hoy”



Transformar datos en conocimiento es el objetivo final del análisis de datos.

1. Concepto de Big Data

¿Qué es un **Dataset**?

- Un Dataset es un **conjunto o colección de datos** recopilados con un propósito específicos en un dominio determinado.
- Pueden estar organizados de forma **estructurada, semi-estructurada, o no estructurada.**

Datos Estructurados	Datos organizados en filas y columnas.	Tabla de clientes con atributos (columnas) como edad, ciudad de residencia, y fecha de última compra
Datos Semi-estructurados	Datos con una estructura flexible pero no estrictamente tabular.	Archivos XML o JSON con detalle de productos
Datos No Estructurados	Datos que no siguen un formato fijo.	Colección de reseñas de texto sobre productos, conjunto de imágenes de productos, audios de canciones.

1. Concepto de Big Data

Fruta	Cantidad	Color
Manzana	4	Rojo
Banana	2	Amarillo
Uva	10	Morado

```
{
  "producto": "Zapatilla",
  "precio": 49.99,
  "tallas": [38, 39, 40]
}
```



“Muy cómodo y fácil de usar. Lo recomiendo.”



“La batería dura poco, pero el diseño es bonito.”

El análisis de datos puede aplicarse a cualquier tipo de dataset, aunque la forma de analizarlos cambiará según su estructura y tipo

Datos Estructurados	Datos organizados en filas y columnas.	Tabla de clientes con atributos (columnas) como edad, ciudad de residencia, y fecha de última compra
Datos Semi-estructurados	Datos con una estructura flexible pero no estrictamente tabular.	Archivos XML o JSON con detalle de productos
Datos No Estructurados	Datos que no siguen un formato fijo.	Colección de reseñas de texto sobre productos, conjunto de imágenes de productos, audios de canciones.

1. Concepto de Big Data

Patrones, tendencias, y relaciones en los datos

- **Patrón:** una característica que se repite de forma frecuente o habitual en un *Dataset*.

→ *Muchos clientes realizan mayores compras los viernes.*

- **Tendencia:** un cambio o evolución en los valores de los datos de forma consistente en el tiempo.

→ *Las ventas online mensuales han ido aumentando en el último semestre.*


- **Relación:** una conexión entre dos variables de los datos (no necesariamente implicando causalidad).

→ A mayor edad, menor es el tiempo de uso diario de redes sociales

Observar estos fenómenos permite interpretar el "comportamiento" de los datos.

Big Data: la revolución del siglo XXI (junto a la IA)

- **Siglo XXI:** avances en tecnología de cómputo, almacenamiento de datos, y algoritmos.
- **Big Data:** conjunto de tecnologías para adquirir, procesar y almacenar datos de un alto ...



- **Valor del Big Data:** transformar datos en *insights* accionables que impulsen decisiones estratégicas

Big Data en cifras

Generación, recolección, y procesamiento de grandes datos en escenarios reales



Redes Sociales

- 4M *likes*/minuto en Facebook
- **Impacto:** personalización y segmentación publicitaria
 - 45-48B\$ ingresos trimestrales de Meta en 2024.

Comercio electrónico

- 2M compras/día en Amazon
- **Impacto:** 35% de ventas a partir de recomendaciones personalizadas basadas en datos.

Finanzas

- 65K transacciones/segundo en Visa
- **Impacto:** detección de fraude en 300ms, protegiendo miles de millones de \$ anuales.

Retos de Big Data

- **Retos técnicos:**

- Almacenamiento y procesamiento de grandes volúmenes de datos (IoT, redes sociales, ...).
- Escalabilidad y rendimiento en infraestructuras.
- Integración de datos altamente heterogéneos.

Tecnologías como **Hadoop** y **Spark** han ayudado a mitigar estos retos, pero la escalabilidad e integración de fuentes de datos heterogéneas sigue siendo compleja

- **Retos de aplicación empresarial**

- Identificar casos de uso relevantes y alineados con objetivos de negocio, organizacionales...
- Convertir grandes datos en conclusiones (*insights*) accionables
- Encontrar recursos humanos especializados, p.ej. científicos de datos cualificados

En **sectores de menor madurez digital**, persiste el desafío de conectar Big Data con resultados tangibles

Retos de Big Data

- **Retos de seguridad y privacidad**
 - Gestión de datos sensibles y protección ante ciberataques
 - Cumplimiento con regulaciones: GDPR, CCPA

Con **nuevas normativas y ciber-amenazas**, la seguridad es un desafío continuo

- **Retos éticos y sociales**
 - Sesgos algorítmicos y transparencia en el uso de datos
 - Confianza del consumidor

Preocupaciones sobre transparencia y uso de datos sensibles bajo un creciente escrutinio

- **Retos económicos:** coste de infraestructura, herramientas y talento

Rentabilizar inversiones en Big Data es ahora más fácil con las **tecnologías en la nube**

Oportunidades de Big Data

- **Optimización empresarial con IA predictiva**
 - Modelos avanzados basados en *machine learning* y *deep learning* guiados por Big Data

Ejemplo: **Tesla** combina datos masivos de sus vehículos y modelos de IA para mejorar la conducción autónoma y predecir fallos, optimizando la experiencia del cliente.

- **Hiper-personalización**
 - Gran volumen y variedad de datos de comportamiento e interacción de usuarios y consumidores, permiten mediante la IA conocer sus necesidades mucho mejor

Ejemplo: **Netflix** emplea Big Data y *machine learning* para recomendar contenidos, de proviniendo el 80% de las visualizaciones de productos de sugerencias personalizadas.

Oportunidades de Big Data

- **Automatización inteligente de procesos**

- Una eficiente y eficaz gestión de grandes datos ayuda a tomar decisiones complejas.

Ejemplo: **Amazon** combina Big Data e IA para automatizar su cadena logística, ajustando inventarios en tiempo real y reduciendo tiempos de entrega.

- **Detección de fraude y vulnerabilidades en tiempo real**

- La velocidad de procesamiento y toma de decisiones automatizada que facilitan las tecnologías de Big Data contribuyen, junto a la IA, a un entorno digital más seguro.

Ejemplo: **Mastercard** usa IA y análisis de Big Data para identificar transacciones fraudulentas al instante, protegiendo millones de dólares diariamente


2. Hadoop y su Ecosistema: base histórica

El "Big Bang" de los Datos

- En 2006, los creadores de **Apache Nutch** (un motor de búsqueda de código abierto) se toparon con un muro: la incapacidad de almacenar y procesar la creciente y masiva base de datos de sitios Web.
- Escalar hacia arriba (supercomputadores) era por entonces inviable e insostenible.
- Solución: escalar "hacia los lados" → conectar ordenadores *low-cost* para almacenar y procesar datos de forma distribuida.
- Así nacía **Apache Hadoop**: software libre para controlar "sistemas montañosos" de datos




2. Hadoop y su Ecosistema: base histórica



2. Hadoop y su Ecosistema: base histórica

Los dos grandes pilares de Hadoop: HDFS y MapReduce


- **HDFS (Hadoop Distributed File System):** almacenamiento de datasets gigantescos en bloques, repartidos en múltiples máquinas y con copias de seguridad ante posibles incidentes.
- **MapReduce:** paradigma de procesamiento distribuido de los datos, llevando el código donde residen los datos y no al revés.



2. Hadoop y su Ecosistema: base histórica

MapReduce explicado en una cocina

- **MAP:** los datos distribuidos, consistentes en pares clave-valor son procesados en paralelo.
- **SHUFFLE:** se redistribuyen y agrupan datos intermedios según su tipo o naturaleza (clave)
- **REDUCE:** se agregan los valores asociados a una misma clave, p.ej. sumar el peso de todas zanahorias picadas.



3. Limitaciones del ecosistema Hadoop Tradicional

Principales "talones de Aquiles" de Hadoop

- **Amnesia de disco:** MapReduce lee y escribe en disco en cada paso, pudiendo llegar a ser muy lento en determinados contextos.
- **Programación verbosa (bajo nivel):** escribir un simple "hola mundo" en MapReduce nativo (Java) requeriría decenas de líneas de código.
- **Sin tiempo real:** está diseñado para procesos batch (lotes de datos procesados a una determinada frecuencia y momento, p.ej. por las noches). Limitado para procesar nuevos datos en vivo.

"Hadoop es un portaaviones robusto y poderoso, pero lento de maniobrar"



3. Limitaciones del ecosistema Hadoop Tradicional

El legado de Hadoop en Python

- **Hadoop Streaming** surgió en 2007 para romper la barrera del lenguaje hasta entonces limitándose a Java, permitiendo el uso conjunto de Hadoop y Python.
- La librería **mrjob**, desarrollada por Yelp en 2010, permitió integrar toda la lógica de MapReduce en un solo script o clase Python → A día hoy, hay librerías mucho más modernas y activas como **Dask**
- Las transformaciones de colecciones en Python (map, reduce, etc.) son funciones nativas muy anteriores a Hadoop, son la base conceptual del Big Data.

Característica	Funciones nativas (map / reduce)	Librería mrjob (Hadoop Streaming)
Año de origen	1994 (Inspiradas en el lenguaje funcional LISP de los años 60)	2010 (Creada por Yelp para Big Data en AWS)
Entorno de ejecución	En memoria local (Un solo hilo/núcleo de tu procesador).	Distribuido en clúster (Cientos de servidores en paralelo).
Volumen de datos	Limitado por la Memoria RAM de tu ordenador.	Escala a Petabytes de datos almacenados en disco (HDFS/S3).
Propósito original	Introducir el paradigma de la programación funcional en Python.	Facilitar la ejecución de código Python sobre clústeres de Hadoop.

4. Motivación para Spark

El puente hacia Spark

- Spark nace en 2009 y es donado a Apache cuatro años después.
- Surge principalmente para solventar la alta dependencia de almacenamiento en disco que sufría Hadoop MapReduce.
- Se introduce el **procesamiento In-Memory** (RAM), manteniendo los datos intermedios del proceso de MapReduce en memoria principal durante toda la ejecución → Hasta **100x en velocidad**.
- Se mantiene lo bueno del Hadoop clásico: **escalabilidad y tolerancia a fallos**.
- **API amigable**: menos código, mayor lógica de negocio.



Evolución: el Porqué del salto a Spark

LA EVOLUCIÓN: POR QUÉ DIMOS EL SALTO A SPARK		
 CARACTERÍSTICA	 HADOOP (MapReduce Clásico)	 APACHE SPARK (PySpark)
MOTOR DE CÁLCULO	 En Disco duro (I/O constante)	 En Memoria RAM (In-Memory)
VELOCIDAD	 Lento (Procesos pesados/nocturnos)	 Hasta 100x más rápido
CÓDIGO Y APIs	 Extenso y complejo (Nativo en Java)	 Conciso y de alto nivel (Python, SQL)
TIPO DE ANÁLISIS	 Solo procesamiento por lotes (Batch)	 Lotes y Tiempo real (Streaming)
COSTE / LICENCIA	 FRE 100% Gratis y Open Source	 FRE 100% Gratis y Open Source